

The background features a stylized illustration of financial data. It includes a blue line graph with an upward trend, a candlestick chart, a city skyline with several skyscrapers, a bar chart, and a tablet displaying a line graph. The entire scene is set against a light blue background with flowing, wavy lines.

Open-FinLLMs: Open Multimodal Large Language Models for Financial Applications

LLMs in Finance Seminar

שמעון יצחק ברקת מילר

11.05.2026

למה צריך LLMs פיננסיים?



“

“Revenue grew 8% YoY, primarily driven by strong performance in the Services segment, which continues to be the company’s main growth engine.”

דורש שילוב בין טקסט ונתונים



• מידע פיננסי מורכב ומגוון



• מודלים כלליים מתמקדים בעיקר בטקסט



• קיים פער בין יכולות LLMs לבין דרישות ניתוח פיננסי

פער בין מודלים כלליים לצרכים פיננסיים

ניתוח פערים : מודלים כלליים אל מול דרישות עולם הפיננסים		
מודלים כלליים		צרכים פיננסיים
טקסטים	✓	טקסטים + טבלאות + גרפים ✗
ידע פיננסי מוגבל	✓	הבנה פיננסית עמוקה ✗
יכולת הסקה מוגבלת	✓	יכולות הסקה מורכבות ✗
יכולת קבלת החלטות מוגבלת	✓	קבלת החלטות מורכבות ורב ממדית ✗

למה זה חשוב?

החלטות פיננסיות מבוססות על שילוב מקורות מידע מגוונים



טעויות בניתוח עלולות להוביל להפסדים וסיכון משמעותי



משימות פיננסיות הן מורכבות ודינמיות



צורך במערכות AI אמינות ומותאמות תחום



מטרת המאמר

- פיתוח מודלי LLM מותאמים לתחום הפיננסי
- שילוב מידע מטקסט, טבלאות, סדרות זמן וגרפים
- שיפור ביצועים במשימות פיננסיות וקבלת החלטות
- גישור על הפער בין מודלים כלליים לצרכים בעולם האמיתי
- בניית מסגרת אחודה הכוללת מספר שלבי אימון



LLMs כלליים – למה זה לא מספיק?

- מודלי LLM מצטיינים בהבנת ויצירת טקסט, אך מאומנים בעיקר על דאטה כללי ולא מותאמים לתחום הפיננסי
- נוצר פער: הבנת שפה $\neq$ הבנת נתונים פיננסיים
- מודלים פיננסיים נועדו לגשר על הפער באמצעות התאמה לדאטה ולמשימות
- טכניקות מרכזיות: Pretraining, Fine-tuning, Instruction tuning



הרעיון המרכזי: Open-FinLLMs

- משפחה של מודלי שפה פיננסיים ייעודיים
- מיועדים להתמודד עם מגוון רחב של משימות פיננסיות
- משלבים מידע מסוגים שונים: טקסט, טבלאות, סדרות זמן וגרפים
- מאחדים מספר שלבי אימון במסגרת אחת (Pretraining, Fine-tuning, Instruction tuning)




מבנה המערכת: Open-FinLLMs



מערכת של שלושה מודלים משלימים ליצירת פתרון מקיף למשימות בעולם הפיננסי

FinLLaMA - מודל בסיס פיננסי

אימון מודל בסיס על דאטה פיננסי רחב כבסיס לכל המערכת




FinLLaMA – Instruct

התאמת מודל הבסיס למשימות בעולם הפיננסי



FinLLaVA - מודל מולטימודלי

הרחבת המודל להבנה משולבת של מידע פיננסי מורכב



החידושים במאמר




- מודלים פיננסיים מולטימודליים בקוד פתוח
- שילוב של טקסט, טבלאות, סדרות זמן וגרפים
- אימון על דאטה פיננסי בהיקף גדול מאוד (52B tokens)
- דאטה ל-Instruction בהיקף רחב (573K דוגמאות)
- תמיכה מלאה ב-multimodal (טקסט, טבלאות, גרפים, סדרות זמן)
- הערכה רחבה על מגוון משימות פיננסיות
- ביצועים טובים יותר ממודלים כלליים ומודלים פיננסיים קיימים

מתודולוגיה: דאטה


- מקורות מגוונים: דוחות, חדשות, נתוני שוק

- שילוב עם דאטה כללי לשימור ידע



מתודולוגיה: מניעת שכחה קטסטרופלית באמצעות DoReMi

- שיטה לאיזון דאטה באימון מודלים
- מתאימה את המשקל של כל מקור מידע כדי לשפר ביצועים
- מאפשרת ניצול יעיל יותר של הדאטה



-  **לחץ כדי להוסיף טקסט**
מתאימה את המשקל של כל מקור מידע
-  **שיפור ביצועים**
מנצלת טוב יותר את המידע הזמין
-  **מניעת שכחה קטסטרופלית**
שומרת על ידע מכל מקורות המידע לאורך האימון

הבטחת אמינות: מניעת דליפת מידע וטיוב נתונים

סינון ואיזון דאטה בתהליך האימון



1

Data
Filtering

מאגרי נתונים גולמיים מרובים

איסוף נתונים ממקורות מגוונים כגון
FLUPE, Sujet-Finance-Instruct
ומאגרי מתמטיקה פיננסית.

2

Deduplication

הסרת 30,000+ דונמאות חופפות

זיהוי ושיוך כפילויות באמצעות נתוח
סטטטי ומדדי דמיון (NER)
למניעת דליפת מידע.

3

Instruction
Data

מאגר דומאות הוראה איכותי

בסיס נתונים איכותי ומאוזן המשמש
לאימון מודל Instruction לביצועים
אופטימליים בעולם האמיתי.

מתודולוגיה: תהליך האימון

- אימון המשך (Continual Pretraining) על דאטה פיננסי להתאמת המודל לתחום
- התאמה למשימות באמצעות Instruction Tuning (שאלות, ניתוחים וקבלת החלטות)
- אימון מולטימודלי (Multimodal Training) לשילוב טקסט, טבלאות, גרפים וסדרות זמן
- תהליך הדרגתי במספר שלבים, שבו כל שלב מוסיף יכולת חדשה



מתודולוגיה: תשתית חומרה ומשאבי חישוב

Stage 1: Pre-Training



64 NVIDIA A100 GPUs (80GB)

Pre-training foundation model

 **250 hours per epoch**

Stage 2: Instruction Tuning



Domain-Specific Optimization


Enhancing financial instruction-following capabilities



 **250 → 6 hours**
Optimization gain

8 NVIDIA A100 GPUs (80GB)

Stage 3: Multimodal Extension



Vision-Language Integration

Processing tables, charts and visual data

 **~30 hours per epoch**
Multimodal training

8 NVIDIA HGX H20 GPUs



From **250 hours** to **6 hours** – Dramatic efficiency gain through optimization

תוצאות: מבט כללי



- נבדק על מגוון משימות ודאטהסטים פיננסיים
- נבחן בתרחישי zero-shot ו-few-shot
- ביצועים חזקים במשימות NLP פיננסיות ומשימות חיזוי
- עולה על מודלים קיימים ברוב המשימות
- נבדק על 14 משימות ו-30 datasets פיננסיים



מגוון דאטה
ומשימות
פיננסיות



הערכה בתרחישי
Zero-shot
Few-shot



ביצועים גבוהים
במשימות NLP
ופיננסיות



עולה על מודלים
קיימים
ברוב המקרים

תוצאות מרכזיות

- ביצועים גבוהים בניתוח סנטימנט וסיווג טקסטים פיננסיים
- שיפור ביכולת reasoning וקבלת החלטות
- הצלחה במשימות פיננסיות כמו הערכת סיכון וזיהוי הונאות
- המודל המולטימודלי מצטיין בעבודה עם נתונים מורכבים
- שיפור בדיוק בסנטימנט: 81% (לעומת 75%)
- שיפור בדיוק בסיווג טקסטים: 86% (לעומת 73%)
- שיפור בדיוק במענה לשאלות פיננסיות (QA): 51% (לעומת 32%)
- שיפור בזיהוי ישויות (NER): 82% (לעומת 39%)

מודל מולטימודלי (FinLLaVA)

- המודל החזק ביותר מבין מודלים בקוד פתוח (Open-source)
- ביצועים גבוהים יותר מ: LLaVA, Qwen-VL ו-DeepSeek-VL
- ביצועים תחרותיים מול מודלים סגורים (GPT-4o ו-Gemini)
- ביצועים מובילים בניתוח טבלאות: 72.4% ב-TableBench (הגבוה ביותר)
- ביצועים טובים בהשוואה ל-GPT-4o ו-Gemini במשימות טבלאיות
- יכולת מתקדמת לניתוח טבלאות, גרפים וטקסט יחד

	Method	Backbone	MMMU-Overall*	MMMU-Bussniess*	ChartBench [†]	TableBench [†]
Closed Source	Gemini-1.5-pro	-	49.3	49.8	61.4	58.2
	GPT-4o	-	55.7	64.3	66.3	66.7
	Qwen-VL-MAX	-	46.8	39.8	56.0	55.4
Open Source	LLaVA-1.5	Vicuna-7B	32.0	26.3	43.4	56.0
	LLaVA-1.5	Vicuna-13B	33.6	29.0	49.1	69.1
	LLaVA-1.6	Vicuna-7B	32.3	25.6	41.7	42.9
	LLaVA-1.6	Vicuna-13B	34.0	29.1	50.3	59.3
	Deepseek-VL-7B-Chat	DeepSeek-LLM-7B-Base	34.2	28.6	51.4	57.3
	Qwen-VL-Chat	Qwen-7B	32.0	26.2	52.6	48.2
	FinLLaVA	FinLLaMA	36.3	30.7	52.9	72.4

מגבלות

- מודל גדול (כ-8B פרמטרים) - מגביל ביצועים במשימות מורכבות
- מבוסס בעיקר על דאטה באנגלית - מגביל שימוש גלובלי
- עלות חישובית גבוהה לאימון ולשימוש
- פער אפשרי בין ביצועים על benchmark לבין שימוש בעולם אמיתי



הערת רפרודוקטיביות

- המודל המקורי שמוצג במאמר TheFinAI/FinLLaMA-instruct הוסר מ-Hugging Face
- באימפלמנטציה השתמשנו ב-plutus-8B-instruct פברואר 2025, (היורש הרשמי של אותה קבוצת מחקר).
- זו דוגמה אמיתית ל-reproducibility risk ב-LLM benchmarks



ניתוח ביקורתי

- למרות תהליכי סינון וניקוי הדאטה, עדיין קיים סיכון להטיות או דליפות מידע (data leakage)
- ההערכה מוגבלת ואינה משקפת בהכרח קבלת החלטות אמיתית
- מורכבות גבוהה של המודל עלולה להקשות על יישום בפועל
- צורך בבדיקות נוספות בעולם האמיתי (real-world validation)
- **סיכון רפרודוקטיביות:** המודל המקורי FinLLaMA-instruct הוסר מ-Hugging Face בשל בעיה אמיתית בשטח



חשיבות לעולם הפיננסי

- תמיכה בקבלת החלטות פיננסיות בעולם האמיתי
- ניתוח מידע ממקורות מגוונים (דוחות, חדשות, נתוני שוק)
- ייעול תהליכים פיננסיים מורכבים, כמו חיזוי והערכת סיכונים
- פוטנציאל ליישומים רחבים מסחר, השקעות ורגולציה



סיכום

- גישה מולטימודלית בקוד פתוח: המודל הראשון שמשלב טקסט, טבלאות,

סדרות זמן וגרפים יחד

- B8 מנצח גדולים יותר: עוקף את BloombergGPT בגודל B50, ומתחרה

במודלים סגורים

- תוצאות אמיתיות בשטח: קפיצה דרמטית במשימות מורכבות (NER: 82%→39%)

ורוחיות במסחר

- אך נדרש זהירות: פער benchmark מול עולם אמיתי, ומגבלות שפה ועלות



תודה

